

Trabalho Prático

ESTATÍSTICA DESCRITIVA

Cody Stefano Barham Setti – 4856322

Vinícius de Sá Ferreira – 15491650

16 de Abril de 2026

São Carlos, SP, Brasil

Da plataforma de competições de ciência de dados *Kaggle* — uma subsidiária da *Google* — extraímos o banco de dados `titanic.csv`, que contém uma série de informações sobre 891 passageiros do infame Titanic.

Para nosso trabalho, contudo, focamos em apenas três dados de cada passageiro:

1. sexo (“feminino” ou “masculino”);
2. idade, em anos;
3. preço de seu bilhete, em libras esterlinas (£).

Consideramos para nossos cálculos apenas passageiros sem dados faltantes. Portanto, restringimo-nos a 714 deles. Ao se tratar da modelagem que fizemos de cada conjunto de dados:

1. Os valores “feminino” e “masculino” não são quânticos nem ordenáveis. Portanto, interpretamos os sexos dos passageiros como amostragens de uma **variável qualitativa nominal**.
2. Arredondamos as idades¹ a anos inteiros — já que algumas são registradas de forma fracionária no arquivo `titanic.csv`. Logo, após o arredondamento, interpretamos as idades como amostragens de uma **variável quantitativa discreta**.
3. No momento de venda, em 1912, os bilhetes do Titanic foram cobrados no sistema monetário *Sterling* antigo, com valores dados em libras, xelins e pence. Todavia, no banco de dados `titanic.csv` — disponibilizado no *Kaggle* em 2012 — estes valores foram convertidos ao novo sistema *Sterling*, de 1971 em diante. Portanto, cada valor é dado por um único número de libras, embora seja frequentemente um número fracionário. Com isso em mente, interpretamos os preços como amostragens de uma única **variável quantitativa contínua**.

a) Com base no rol, calcular a média, mediana e moda e compare-as

Tabela 1: Medidas de posição dos conjuntos de dados

	Sexo	Idade (anos)	Preço (£)
$\bar{X}$	-	29,69	34,69
Md	-	28,00	15,74
Mo	masculino	24,00	13,00

¹As idades sofreram “arredondamento bancário”, especificamente.

[INSERIR INTERPRETAÇÃO]

b) Com base no rol, calcular os quartis, interpretando-os

Tabela 2: *Quartis das idades e dos preços dos bilhetes dos passageiros*²

	Idade (anos)	Preço (£)
Q_1	20	8,05
Q_2	28	15,74
Q_3	38	33,25

[INSERIR INTERPRETAÇÃO]

c) Calcular a amplitude total, amplitude interquartílica, o desvio-padrão e coeficiente de variação. Ressaltar dentre as variáveis quantitativas qual tem maior variabilidade

Tabela 3: *Medidas de dispersão dos conjuntos de dados quantitativos*

	Idade (anos)	Preço (£)
A	80,00	512,33
d_Q	18,00	25,20
S	14,52	52,92
$CV(\%)$	48,92	152,53

O coeficiente de variação dos preços é maior do que o das idades e, portanto, a variável associada aos preços possui variabilidade maior do que a associada às idades.

d) Com a comparação das medidas de tendência central, avaliar a simetria

Tanto no caso das idades, quanto no caso dos preços, a mediana é inferior à média. Portanto, ambos os conjuntos possuem assimetria à direita.

e) Sumarizar as informações em tabela

Para sumarizar as informações relativas a sexo, como apenas duas categorias foram registradas, optamos por uma tabela de frequência simples.

Tabela 4: *Frequência de sexos*

Sexo	Frequência
Feminino	261
Masculino	453

²Quartis de índices fracionários foram calculados pela média simples dos dois valores de índices mais próximos.

Para as idades e os preços, todavia, que são muitos, optamos por tabelas de frequência por classes. Para as idades, as classes elegidas foram décadas. Para os preços, elegemos 11 classes de mesma amplitude, conforme sugere a regra de Sturges.

Tabela 5: *Frequência de idades por década*

Faixa Etária (anos)	Frequência
0 – 10	62
10 – 20	102
20 – 30	220
30 – 40	167
40 – 50	89
50 – 60	48
60 – 70	19
70 – 80	6
80 – 90	1

Tabela 6: *Frequência de preços de bilhetes por classes*

Preço (£)	Frequência
0,000 – 46,575	566
46,575 – 93,151	98
93,151 – 139,726	22
139,726 – 186,302	10
186,302 – 232,877	7
232,877 – 279,452	8
279,452 – 326,028	0
326,028 – 372,603	0
372,603 – 419,178	0
419,178 – 465,754	0
465,754 – 512,842	3

f) Com base nas informações tabeladas, calcular a média, mediana, moda, os quartis e o desvio-padrão. Compare os valores das medidas obtidas com o rol.

Tabela 7: *Medidas reconstruídas a partir das tabelas de frequência*

	Sexo	Idade (anos)	Preço (£)
$\bar{X}$	-	30,25	40,90
Md	-	25,00	23,29
Mo	masculino	25,00	23,29
Q_1	-	25,00	23,29
Q_2	-	25,00	23,29
Q_3	-	35,00	23,29
S	-	14,97	48,91

Primeiramente, como o sexo dos passageiros foi tabelado seguindo frequências simples, não há perda de informações, ou seja, as estatísticas devem permanecer idênticas. Pelo outro lado, como a variável associada é qualitativa nominal, ela apresenta uma única estatística: sua moda.


Por sua vez, ao se tratar das estatísticas relativas à idade dos passageiros e ao preço de seus bilhetes, a começar, vemos que as médias reconstruídas estão deslocadas à direita das originais, mas os valores são próximos.

Tanto para a idade dos passageiros, quanto para o preço de seus bilhetes, há uma classe significativamente mais frequente do que todas outras, 20 – 30 anos e 0 £ – 46,575 £, respectivamente. Para o preço, em particular, essa diferença de frequência é gritante.


Consequentemente, a mediana, a moda e os quartis desses dados convergem ao ponto médio de tal classe, 25 anos ou 23, 29 £. Para a idade, este efeito não é tão forte, afinal, $Q_3 = 35$ anos, o ponto médio da classe seguinte. Mas, para o preço, todos quartis reconstruídos coincidiram em 23, 29 £.

Por fim, o desvio padrão das idades aumentou muito ligeiramente, ao passo que o dos preços diminui ligeiramente. Acreditamos que a diminuição — no caso dos preços — deve-se ao fato de preços, antes próximos, agora serem valorados no preço idêntico de 23, 29 £.

g) Sumarizar as informações de cada variável graficamente (apresente dois gráficos), interpretando-as. Para a variável quantitativa contínua, apresentar obrigatoriamente o histograma e o *boxplot*.




(a) Gráfico de barras




(b) Gráfico de setores

Figura 1: Gráficos relativos aos sexos dos passageiros

Ambos os gráficos, mas, em especial, o de setores, mostram que a tripulação masculina do Titanic era próxima do dobro da feminina. Ou, ao menos, este era o caso para o subconjunto de 714 passageiros avaliados.



(a) Histograma



(b) Boxplot

Figura 2: Gráficos relativos às idades dos passageiros

O histograma ilustra uma distribuição unimodal com assimetria à direita, mostrando que 20 – 30 é a faixa etária mais frequente.

O *boxplot* também nos evidencia assimetria à direita. A começar, sua “caixa” nos informa que 50% dos passageiros possuem entre 20 a 38 anos. Todavia, sua linha mediana (28 anos) está ligeiramente deslocada para baixo. Por fim, ele destaca a presença de *outliers* à direita — valores acima de seu “bigode” superior — o que corresponde à minoria de passageiros idosos do Titanic.




Figura 3: Gráficos relativos aos preços dos bilhetes dos passageiros

Tanto o histograma, quanto o *boxplot* indicam uma extrema assimetria à direita nos preços. No histograma, a primeira barra (bilhetes mais baratos) concentra quase todos os dados, enquanto as demais formam uma cauda longa e quase invisível.

O *boxplot*, por sua vez, apresenta não só uma linha mediana mais próxima de Q_1 do que Q_3 , mas a “caixa” como um todo é muito estreita, seguida por uma longa sequência de *outliers* à direita.

Tal configuração faz sentido se considerarmos que a maioria dos passageiros viajaram em cabines simples, ao passo que alguns seletos alugaram cabines de luxo.